

experimento 1

nesse experimento é testado o desempenho individual das cinco arquiteturas das redes neurais convolucionais (CNN) pré-treinadas

Ex:

RESNET50

**backbone
congelado**

Camadas finais
antes do vetor
final
descongeladas
com LR baixo

vetor após camada Dense

Camadas adicionais com Lr
alto

Softmax

Métricas:

A capacidade de cada modelo para classificar os tipos de câncer de pele é medida utilizando métricas padrão: **acurácia, precisão, revocação (recall) e F1-score**

Esse experimento tem como **propósito gerar métricas claras**, de forma que exista uma **base comparativa** clara ao realizar o **experimento 2**, que irá realizar a **adição de metadados do paciente na avaliação**

Experimento 2

Aqui a proposta passa a ser, oque ocorre, além da imagem, eu adiciono metadados clínicos?

De um lado mantemos o mesmo processo em paralelo com a CNN do experimento 1

metadado tabulares

- age_approx
- anatom_site_general
- benign_malignant
- sex
- diagnosis s41598-025-30534-z.pdf

one-hot-encoding

Agora os campos categóricos viram vetores binários.

Etapa 4 — padronização do valor numérico

A idade não entra como "52" cru.

Ela é padronizada com z-score normalization. s41598-025-30534-z.pdf

Se a média da idade for 45 e o desvio padrão 10, então:

$$z = \frac{52 - 45}{10} = 0,7$$

Então:

Plain text
age_approx = 52 → 0.7

Copiar

Etapa 5 — vetor tabular final

Depois disso, tudo é concatenado em um único vetor numérico.

Exemplo:

Plain text
idade_padronizada = [0.7]
sex = [0,1,0]
anatom_site_general = [0,0,0,0,1,0]
benign_malignant = [0,1]


Copiar

Vetor de entrada tabular:

Plain text
[0.7, 0,1,0, 0,0,0,0,1,0, 0,1]

Copiar

Vetor passa por uma rede neural



vetor tabular

- Dense(32)
- ReLU
- Dropout
- BatchNorm
- Dense(64)
- ReLU
- Dropout
- BatchNorm
- vetor final de metadados

Concatenação com vetor da CNN


Softmax

multi modal deep learning

CNN

Através dos resultados dos experimentos 2, foi separado **es 3 CNN** que apresentaram os melhores resultados com a concatenação com os dados tabulares

a entrada passa por 3 CNN em paralelo



vetor final

vetor final

vetor final

Ensemble adaptativo

A cada saída do modelo é atribuído pesos

com base nesse valores é calculado a **predição final**

peso atribuído a saída do modelo

$$p = w_1 p_1 + w_2 p_2 + w_3 p_3$$

Vetor do modelo

durante a **retropropagação** esses **pesos** tendem a **aumentar ou diminuir** dependendo do impacto no erro final

vetores são concatenados (posicionados lado e lado)

metadados tabulares

one-hot-encoding

Agora os campos categóricos viram vetores binários.

Etapa 4 — padronização do valor numérico

A idade não entra como "52" cru.

Ela é padronizada com z-score normalization.

Se a média da idade for 45 e o desvio padrão 10, então:

$$z = \frac{52 - 45}{10} = 0,7$$

Então:

Plain text
age_approx = 52 → 0.7

Etapa 5 — vetor tabular final

Depois disso, tudo é concatenado em um único vetor numérico.


Exemplo:

Plain text
idade_padronizada = [0.7]
sex = [0,1,0]
anatom_site_general = [0,0,0,0,1,0]
benign_malignant = [0,1]

Vetor de entrada tabular:

Plain text
[0.7, 0,1,0, 0,0,0,0,1,0, 0,1]

Vetor passa por uma rede neural



vetor tabular
→ Dense(32)
→ ReLU
→ Dropout
→ BatchNorm
→ Dense(64)
→ ReLU
→ Dropout
→ BatchNorm
→ vetor final de metadados

classificação
(softmax)